Biais de confusion et transport de l'ATE avec un traitement binaire et des confondeurs multiples

Elias Massaro

October 4, 2026

1 Modèle

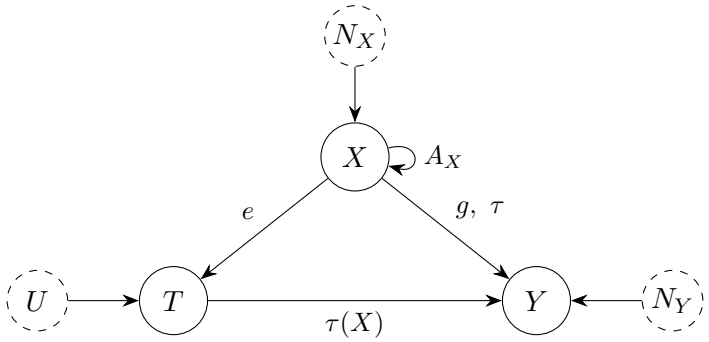


Figure 1: Graphe causal. Le nœud $X \in \mathbb{R}^p$ représente le bloc des confondeurs ; la boucle représente les arêtes entre ses composantes, de poids $(A_X)_{ij}$ pour $X_j \to X_i$. Les variables en pointillés sont exogènes.

Hypothèse 1 (Bloc confondeur)**.** $X = (X_1, \dots, X_p)^\top$ est engendré par le SCM linéaire

$$X := A_X X + N_X,$$

où $A_X \in \mathbb{R}^{p\times p}$ est la matrice des poids d'un graphe orienté acyclique, $(A_X)_{ij}$ étant le poids de l'arête $X_j \to X_i$, et où N_X est un vecteur aléatoire de $\mathbb{R}^p$ de loi quelconque.

Dans un ordre topologique du graphe, A_X est strictement triangulaire inférieure, donc $A_X^p = 0$; $I - A_X$ est alors inversible, d'inverse $B_X := \sum_{k=0}^{p-1} A_X^k$, et $X = B_X N_X$.

Hypothèse 2 (Traitement)**.** Il existe une fonction mesurable $e : \mathbb{R}^p \to [0,1]$ et une variable U de loi uniforme sur $[0,1]$, indépendante de N_X, telles que

$$T := \mathbf{1}\{U \le e(X)\} \in \{0,1\}. \tag{1}$$

On note $\pi := \mathbb{E}[e(X)]$ et on suppose $0 < \pi < 1$.

Hypothèse 3 (Résultat)**.** Il existe des fonctions mesurables $g, \tau : \mathbb{R}^p \to \mathbb{R}$ avec $\mathbb{E}|g(X)| < \infty$, $\mathbb{E}|\tau(X)| < \infty$, et un bruit N_Y intégrable, indépendant de (N_X, U), tels que

$$Y := g(X) + \tau(X)\, T + N_Y. \tag{2}$$

Remarque 1.1. Pour toute fonction mesurable $f : \mathbb{R}^p \times \{0,1\} \to \mathbb{R}$ et tout $t \in \{0,1\}$, $f(x,t) = f(x,0) + t\,\big(f(x,1) - f(x,0)\big)$. Toute équation $Y := f(X,T) + N_Y$ avec N_Y indépendant de (N_X, U) est donc de la forme (2), avec $g = f(\cdot,0)$ et $\tau = f(\cdot,1) - f(\cdot,0)$ (Additive Noise Model graçe à la binarité de T).

2 Estimande et pente naïve

Lemme 2.1 (Régression, intervention, estimande)**.** *Sous les Hypothèses 1–3 :*

(i) N_Y *est indépendant de* (X, T)*, et* $\mathbb{E}[T \mid X] = e(X)$ *;*

(ii) Y *et* TY *sont intégrables, et* $\mathbb{E}[Y \mid X, T] = g(X) + \tau(X)\, T + \mathbb{E}[N_Y]$ *;*

(iii) pour $t \in \{0, 1\}$*,* $\mathbb{E}\big[Y \mid \mathrm{do}(T = t)\big] = \mathbb{E}[g(X)] + t\, \mathbb{E}[\tau(X)] + \mathbb{E}[N_Y]$*, donc*

$$\mathrm{ATE}(\mathcal{M}) := \mathbb{E}\big[Y \mid \mathrm{do}(T = 1)\big] - \mathbb{E}\big[Y \mid \mathrm{do}(T = 0)\big] = \mathbb{E}[\tau(X)]. \tag{3}$$

démonstration : annexe A, p. 4

On pose

$$\beta := \frac{\mathrm{Cov}(T, Y)}{\mathrm{Var}(T)}, \qquad \lambda := \beta - \mathrm{ATE}(\mathcal{M}). \tag{4}$$

Lemme 2.2 (Identités élémentaires)**.** *Sous les Hypothèses 1 et 2, pour toute fonction mesurable* h *telle que* $\mathbb{E}|h(X)| < \infty$*,*

$$\begin{aligned} T^2 = T, \qquad & \mathrm{Var}(T) = \pi(1 - \pi), \\ \mathbb{E}\big[T\, h(X)\big] = \mathbb{E}\big[e(X)\, h(X)\big], \qquad & \mathrm{Cov}\,\big(T, h(X)\big) = \mathrm{Cov}\,\big(e(X), h(X)\big). \end{aligned} \tag{5}$$

Sous l'Hypothèse 3 en plus, $\beta = \mathbb{E}[Y \mid T = 1] - \mathbb{E}[Y \mid T = 0]$*.*

démonstration : annexe A, p. 4

3 Le biais de confusion

Théorème 3.1. *Sous les Hypothèses 1–3,*

$$\boxed{\lambda \;=\; \frac{\mathrm{Cov}\,\big(e(X),\, g(X)\big) \;+\; (1 - \pi)\ \mathrm{Cov}\,\big(e(X),\, \tau(X)\big)}{\mathrm{Var}(T)}} \tag{6}$$

avec $\mathrm{Var}(T) = \pi(1 - \pi)$*.*

démonstration : annexe A, p. 4

Corollaire 3.2 (Cas g linéaire, τ affine)**.** *Supposons de plus* $\mathbb{E}\|X\| < \infty$*.*

(i) Si $g(x) = b^\top x$ *avec* $b \in \mathbb{R}^p$*, alors*

$$\lambda = \frac{b^\top\, \mathrm{Cov}(X, T) + (1 - \pi)\ \mathrm{Cov}\,\big(e(X), \tau(X)\big)}{\mathrm{Var}(T)}.$$

(ii) Si de plus $\tau(x) = \tau_0 + \gamma^\top x$ *avec* $\tau_0 \in \mathbb{R}$ *et* $\gamma \in \mathbb{R}^p$*, alors*

$$\lambda = \frac{\big(b + (1 - \pi)\, \gamma\big)^\top\ \mathrm{Cov}(X, T)}{\mathrm{Var}(T)}.$$

démonstration : annexe A, p. 4

Remarque 3.3 (Lecture de λ)**.** Le Théorème 3.1 s'écrit

$$\begin{aligned}\lambda &= \frac{\operatorname{Cov}\big(e(X), g(X)\big)}{\pi(1-\pi)} + \frac{\operatorname{Cov}\big(e(X), \tau(X)\big)}{\pi} \\ &= \Big(\mathbb{E}[g(X) \mid T=1] - \mathbb{E}[g(X) \mid T=0]\Big) + \Big(\mathbb{E}[\tau(X) \mid T=1] - \mathbb{E}[\tau(X)]\Big),\end{aligned} \tag{7}$$

la seconde égalité étant démontrée en annexe A.

- *Premier terme : confusion par g.* C'est l'écart, entre traités et non traités, de la moyenne de $g(X)$, partie de Y qui ne dépend pas du traitement. Il est non nul si et seulement si $e(X)$ et $g(X)$ sont corrélées, c'est-à-dire quand les confondeurs qui modifient la probabilité d'être traité modifient aussi g.
- *Second terme : hétérogénéité de l'effet.* C'est l'écart entre l'effet moyen chez les traités, $\mathbb{E}[\tau(X) \mid T=1]$, et l'effet moyen dans toute la population, $\mathbb{E}[\tau(X)] = \mathrm{ATE}(\mathcal{M})$. Il est non nul si et seulement si $e(X)$ et $\tau(X)$ sont corrélées. Il est nul si τ est constante.
- *Cas où $\lambda = 0$.* (a) $e(X)$ est p.s. constante, par exemple e constante (traitement tiré au hasard indépendamment de X) : les deux covariances sont nulles. (b) τ est constante et $\operatorname{Cov}(e(X), g(X)) = 0$: les deux termes sont nuls. (c) Compensation : $\operatorname{Cov}(e(X), g(X)) = -(1-\pi)\operatorname{Cov}(e(X), \tau(X)) \neq 0$; les deux termes sont non nuls et opposés.

démonstration : annexe A, p. 5

4 Première variation et transport

Le domaine cible $\mathcal{M}^*$ diffère du domaine source $\mathcal{M}$ par le seul coefficient de traitement :

$$\tau^* = \tau + \Delta\tau, \qquad \mathbb{E}|\Delta\tau(X)| < \infty, \tag{8}$$

A_X, la loi de N_X, e et g étant inchangés ; N_Y peut changer de loi, en restant intégrable et indépendant de (N_X, U). On note β^* et λ^* les quantités correspondantes.

Proposition 4.1 (Première variation)**.** *Sous les Hypothèses 1–3 et le régime* (8)*,*

$$\mathrm{ATE}(\mathcal{M}^*) - \mathrm{ATE}(\mathcal{M}) = \mathbb{E}\big[\Delta\tau(X)\big], \qquad \lambda^* - \lambda = \frac{\operatorname{Cov}\big(e(X), \Delta\tau(X)\big)}{\pi}. \tag{9}$$

démonstration : annexe A, p. 5

Théorème 4.2 (Transport par les deux pentes naïves)**.** *Sous les mêmes hypothèses, les trois énoncés suivants sont équivalents :*

(i) $\mathrm{ATE}(\mathcal{M}^*) = \mathrm{ATE}(\mathcal{M}) + \big(\beta^* - \beta\big)$ *;*

(ii) $\lambda^* = \lambda$ *;*

(iii) $\operatorname{Cov}\big(e(X), \Delta\tau(X)\big) = 0.$

démonstration : annexe A, p. 5

Corollaire 4.3 (Décalage constant)**.** *Si $\Delta\tau \equiv \Delta$ est constant, alors (iii) est vérifié et* $\mathrm{ATE}(\mathcal{M}^*) = \mathrm{ATE}(\mathcal{M}) + \Delta = \mathrm{ATE}(\mathcal{M}) + (\beta^* - \beta)$.

démonstration : annexe A, p. 5

Corollaire 4.4 (Décalage affine)**.** *Supposons $\mathbb{E}\|X\| < \infty$ et $\Delta\tau(x) = \Delta\tau_0 + \Delta\gamma^\top x$ avec $\Delta\tau_0 \in \mathbb{R}$, $\Delta\gamma \in \mathbb{R}^p$. Alors (iii) équivaut à $\Delta\gamma^\top \mathrm{Cov}(X, T) = 0$.*

démonstration : annexe A, p. 5

A Démonstrations

Démonstration du Lemme 2.1. (i) $X = B_X N_X$ est une fonction de N_X, et T une fonction de (N_X, U) ; comme N_Y est indépendant de (N_X, U), il est indépendant de (X, T). Comme U est indépendante de X et uniforme sur $[0, 1]$, $\mathbb{E}[T \mid X] = \mathbb{P}\big(U \leq e(X) \mid X\big) = e(X)$.

(ii) Comme $|T| \leq 1$, $|Y| \leq |g(X)| + |\tau(X)| + |N_Y|$ et $|TY| \leq |Y|$, qui sont intégrables. En conditionnant (2) par (X, T) et en utilisant (i), $\mathbb{E}[N_Y \mid X, T] = \mathbb{E}[N_Y]$.

(iii) L'intervention $\mathrm{do}(T = t)$ remplace (1) par $T := t$; X, qui ne dépend que de N_X, garde sa loi, et $Y = g(X) + \tau(X)\, t + N_Y$. On prend l'espérance, puis la différence entre $t = 1$ et $t = 0$. □

Démonstration du Lemme 2.2. $T \in \{0, 1\}$ donne $T^2 = T$. Par le Lemme 2.1 (i), $\mathbb{E}[T] = \mathbb{E}[e(X)] = \pi$, donc $\mathrm{Var}(T) = \mathbb{E}[T^2] - \pi^2 = \pi(1-\pi)$. Par la propriété de la tour, $\mathbb{E}[Th(X)] = \mathbb{E}\big[\mathbb{E}[T \mid X]\, h(X)\big] = \mathbb{E}[e(X)h(X)]$, et $\mathrm{Cov}(T, h(X)) = \mathbb{E}[e(X)h(X)] - \mathbb{E}[e(X)]\,\mathbb{E}[h(X)] = \mathrm{Cov}(e(X), h(X))$. Enfin $\mathbb{E}[TY] = \pi\,\mathbb{E}[Y \mid T = 1]$ et $\mathbb{E}[Y] = \pi\,\mathbb{E}[Y \mid T = 1] + (1 - \pi)\,\mathbb{E}[Y \mid T = 0]$, d'où $\mathrm{Cov}(T, Y) = \pi(1 - \pi)\big(\mathbb{E}[Y \mid T = 1] - \mathbb{E}[Y \mid T = 0]\big)$. □

Démonstration du Théorème 3.1. On abrège $e = e(X)$, $g = g(X)$, $\tau = \tau(X)$.

Étape 1. Par (2) et bilinéarité, $\mathrm{Cov}(T, Y) = \mathrm{Cov}(T, g) + \mathrm{Cov}(T, T\tau) + \mathrm{Cov}(T, N_Y)$, et $\mathrm{Cov}(T, N_Y) = 0$ par le Lemme 2.1 (i).

Étape 2. $\mathrm{Cov}(T, g) = \mathrm{Cov}(e, g)$ par le Lemme 2.2.

Étape 3. Par $T^2 = T$ puis le Lemme 2.2,

$$\mathrm{Cov}(T, T\tau) = \mathbb{E}[T^2\tau] - \mathbb{E}[T]\,\mathbb{E}[T\tau] = (1 - \pi)\,\mathbb{E}[T\tau] = (1 - \pi)\,\mathbb{E}[e\tau].$$

Étape 4. Par le Lemme 2.1 (iii), $\mathrm{ATE}(\mathcal{M}) = \mathbb{E}[\tau]$, et $\mathrm{Var}(T) = \pi(1 - \pi)$:

$$\lambda = \frac{\mathrm{Cov}(e, g) + (1 - \pi)\,\mathbb{E}[e\tau] - \pi(1 - \pi)\,\mathbb{E}[\tau]}{\mathrm{Var}(T)} = \frac{\mathrm{Cov}(e, g) + (1 - \pi)\,\big(\mathbb{E}[e\tau] - \mathbb{E}[e]\,\mathbb{E}[\tau]\big)}{\mathrm{Var}(T)},$$

car $\mathbb{E}[e] = \pi$. On reconnaît $\mathrm{Cov}(e, \tau)$. □

Démonstration du Corollaire 3.2. Le Lemme 2.2 appliqué à $h(X) = X_j$ donne $\mathrm{Cov}(X, e(X)) = \mathrm{Cov}(X, T)$. Donc $\mathrm{Cov}(e(X), b^\top X) = b^\top \mathrm{Cov}(X, T)$, ce qui donne (i) par le Théorème 3.1. De même,

$$\mathrm{Cov}\left(e(X), \tau_0 + \gamma^\top X\right) = \gamma^\top \mathrm{Cov}(X, T),$$

ce qui donne (ii). □

Démonstration des énoncés de la Remarque 3.3. (a) Covariance avec T et différence de moyennes. Soit Z une variable intégrable ; on note $a = \mathbb{E}[Z \mid T = 1]$ et $c' = \mathbb{E}[Z \mid T = 0]$. Par définition, $\mathbb{E}[Z \mid T = t] = \mathbb{E}[Z\,\mathbf{1}\{T = t\}]/\mathbb{P}(T = t)$, avec $\mathbb{P}(T = 1) = \pi$ et $\mathbb{P}(T = 0) = 1 - \pi$.

- Comme $T \in \{0, 1\}$, $TZ = Z\,\mathbf{1}\{T = 1\}$, donc $\mathbb{E}[TZ] = \pi a$.
- Comme $\mathbf{1}\{T = 1\} + \mathbf{1}\{T = 0\} = 1$, $Z = Z\,\mathbf{1}\{T = 1\} + Z\,\mathbf{1}\{T = 0\}$, donc $\mathbb{E}[Z] = \pi a + (1 - \pi)\,c'$.
- Donc $\mathrm{Cov}(T, Z) = \mathbb{E}[TZ] - \mathbb{E}[T]\,\mathbb{E}[Z] = \pi a - \pi\big(\pi a + (1 - \pi)c'\big) = \pi(1 - \pi)\,(a - c')$.

Ainsi

$$\mathrm{Cov}(T, Z) = \pi(1 - \pi)\,\big(\mathbb{E}[Z \mid T = 1] - \mathbb{E}[Z \mid T = 0]\big). \tag{10}$$

(b) Premier terme. Par le Lemme 2.2, $\mathrm{Cov}(e(X), g(X)) = \mathrm{Cov}(T, g(X))$; par (10) avec $Z = g(X)$, $\mathrm{Cov}(e(X), g(X))/(\pi(1 - \pi)) = \mathbb{E}[g(X) \mid T = 1] - \mathbb{E}[g(X) \mid T = 0]$.

(c) Second terme. De même,

$$\frac{\mathrm{Cov}(e(X), \tau(X))}{\pi} = (1 - \pi)\big(\mathbb{E}[\tau(X) \mid T = 1] - \mathbb{E}[\tau(X) \mid T = 0]\big).$$

Par ailleurs $\mathbb{E}[\tau(X)] = \pi\,\mathbb{E}[\tau(X) \mid T = 1] + (1 - \pi)\,\mathbb{E}[\tau(X) \mid T = 0]$ (second point de (a) avec $Z = \tau(X)$), d'où

$$\mathbb{E}[\tau(X) \mid T = 1] - \mathbb{E}[\tau(X)] = (1 - \pi)\big(\mathbb{E}[\tau(X) \mid T = 1] - \mathbb{E}[\tau(X) \mid T = 0]\big).$$

Les deux membres sont égaux, ce qui donne (7). Les caractérisations « non nul si et seulement si » viennent de $\pi(1 - \pi) > 0$. □

Démonstration de la Proposition 4.1. La loi de X est la même dans les deux domaines ; la première identité suit de (3). La loi de (X, T) est la même dans les deux domaines, donc π, $\mathrm{Var}(T)$ et e aussi, et g est inchangée. Le membre de droite de (6) ne dépend de τ que par le terme linéaire $(1-\pi)\,\mathrm{Cov}(e, \tau)$. On substitue $\tau^* = \tau + \Delta\tau$, on soustrait, et on utilise $\mathrm{Var}(T) = \pi(1 - \pi)$. □

Démonstration du Théorème 4.2. $(ii) \Leftrightarrow (iii)$ par (9)‘. Par définition, $\beta = \mathrm{ATE}(\mathcal{M}) + \lambda$ dans chaque domaine, donc

$$\beta^* - \beta = \big(\mathrm{ATE}(\mathcal{M}^*) - \mathrm{ATE}(\mathcal{M})\big) + \big(\lambda^* - \lambda\big),$$

et (i) équivaut à $\lambda^* - \lambda = 0$. □

Démonstration du Corollaire 4.3. $\mathrm{Cov}(e(X), \Delta) = 0$; on applique le Théorème 4.2, et $\mathbb{E}[\Delta\tau(X)] = \Delta$ par (9). □

Démonstration du Corollaire 4.4. $\mathrm{Cov}\left(e(X), \Delta\tau_0 + \Delta\gamma^\top X\right) = \Delta\gamma^\top\,\mathrm{Cov}(X, e(X)) = \Delta\gamma^\top\,\mathrm{Cov}(X, T)$ par le Lemme 2.2. □